

Lyra - Arquitetura e Ferramentas

Visao Geral

A Lyra e uma assistente pessoal local, rodando inteiramente no PC do usuario (sem dependencia de nuvem para suas funcoes principais). A stack combina um modelo de linguagem local (Ollama), memoria vetorial (Qdrant), memoria estruturada (SurrealDB) e um orquestrador HTTP (FastAPI) que conecta tudo isso ao function-calling das ferramentas nativas.

Documento gerado automaticamente para refletir o estado atual da stack, incluindo a leva de ferramentas adicionada em 24/06/2026.

Arquitetura da Stack

Servicos

- SurrealDB (porta 8090) - namespace lyra_core, banco Db_CORTEX, storage local em surrealkv. Guarda tabelas estruturadas: base_codigo, base_conhecimento_qa, base_instrucoes_ptbr, base_raciocinio, base_conversas (a maior, 1 milhao+ registros), base_medicina_ptbr, evento, lembrete, numero, agendamento, processo_bg, tarefa.
- Qdrant (porta 6333) - colecao de producao lyra_memory (embeddings MiniLM multilingual, 384 dimensoes). Colecao paralela lyra_memory_v2 em migracao para BGE-M3 (1024 dimensoes), sem nunca tocar a producao.
- Ollama (porta 11434) - modelo de chat principal "Lyra" (alias customizado); modelo qwen2.5-coder:7b usado pelo especialista de codigo.
- cerebro_maestro.py (FastAPI, porta 8000) - orquestrador central: RAG hibrido automatico (busca densa no Qdrant + BM25 lexical, combinados por Reciprocal Rank Fusion) injetado no prompt antes de chamar o Ollama; function-calling via lyra_tools.py; loop proativo assincrono que roda a cada 60 segundos.

Boot Automatico

Sem Task Scheduler (ambiente bloqueia schtasks). Um atalho na pasta Startup do Windows chama um script VBS oculto, que dispara em sequencia os bats de Qdrant, SurrealDB e cerebro_maestro - cada um checando antes se a porta ja esta

respondendo, para nunca duplicar processo. O Front_end_Lyra fica deliberadamente fora do boot automatico.

Migracao de Embeddings (BGE-M3)

Em andamento desde 22-23/06/2026: migrando de paraphrase-multilingual-MiniLM-L12-v2 (384-dim) para BAAI/bge-m3 (1024-dim), em ambiente Python isolado (venv_embed). Grava em colecao paralela lyra_memory_v2, com checkpoint por tabela e reconexao resiliente ao SurrealDB. Status no momento deste documento: tabela base_conversas em processamento (101.000 de 1.001.379 linhas, aproximadamente 10%). Apos concluir, falta: validar contagens, comparar qualidade de busca lado a lado, e so entao trocar producao com aprovacao explicita do usuario.

Inventario Completo de Ferramentas (lyra_tools.py)

Arquivos e Sistema

- ler_arquivo / escrever_arquivo / listar_arquivos / organizar_pasta
- executar_comando (PowerShell, com timeout)
- abrir_app (programas ou URLs)
- capturar_tela (screenshot + OCR via EasyOCR na GPU)
- ler_clipboard / escrever_clipboard

Memoria e Busca

- buscar_memoria / salvar_memoria (RAG hibrido RRF no Qdrant lyra_memory)
- pesquisar_internet (busca anonima via DuckDuckGo)
- buscar_url (extrai texto principal de uma URL especifica)
- ler_documento (extrai texto de PDF, DOCX, TXT, MD, CSV)
- traduzir_texto (traducao via o proprio modelo Ollama local, sem API externa)

Geracao de Conteudo

- gerar_documento (PDF, DOCX, XLSX, HTML, TXT)

Lembretes, Numeros e Notificacoes

- gerenciar_lembretes (CRUD com data/hora marcada)
- Sistema de Numeros, inspirado na Maquina de Person of Interest: registrar_numero registra uma observacao com score de relevancia (0 a 1) sem interromper na hora; listar_numeros consulta o que cruzou o limiar e ainda nao foi notificado
- notificar_usuario (toast nativo do Windows)
- notificar_celular (push via ntfy.sh, alcanca o usuario mesmo fora do PC)
- obter_topico_celular (retorna o topico secreto para inscricao no app ntfy)

Agendamentos e Processos em Background

- gerenciar_agendamentos (tipo cron: unico, diario ou por intervalo de minutos; pode disparar outra ferramenta automaticamente quando o horario chega)
- iniciar_processo_bg / status_processo_bg / listar_processos_bg (executa comandos longos sem bloquear o chat; o loop proativo detecta quando o processo termina e notifica sozinho)
- gerenciar_tarefas (lista de tarefas / to-do para pedidos com varias etapas)

Seguranca, Backup e Diagnostico

- checar_saude_sistema (CPU, RAM, GPU via psutil e GPUtil)
- backup_memoria (exporta todas as tabelas do SurrealDB para JSON com timestamp, mais snapshot das colecoes Qdrant)
- consultar_git (consulta somente-leitura de repositorios: status, log, diff, branch - sem commit, push ou checkout)
- consultar_especialista (delega tarefas de codigo complexas para o Qwen Coder local; uso de nuvem bloqueado sem aprovacao explicita do usuario)

Auto-Extensao

- criar_ferramenta (gera codigo Python de uma nova ferramenta, escaneando padroes de risco antes de liberar)
- listar_ferramentas_ext (lista ferramentas criadas dinamicamente)
- aprovar_ferramenta_ext (somente o usuario aprova manualmente; deliberadamente fora do function-calling, a Lyra nao pode se autoaprovar)

Loop Proativo

A cada 60 segundos, o `cerebro_maestro.py` verifica automaticamente:

- Lembretes vencidos -> dispara `notificar_usuario` e marca como concluido
- Numeros que cruzaram o limiar de relevancia -> notifica e marca como notificado
- Agendamentos cuja hora chegou -> executa a ferramenta vinculada (se houver) e recalcula a proxima execucao
- Processos em background que terminaram -> notifica com as ultimas linhas do log

Esse loop foi escrito em 24/06/2026 e depende de um reinicio do `cerebro_maestro.py` para entrar em vigor (estava aguardando o fim da vetorizacao BGE-M3 para nao competir por recursos de GPU/CPU).

Seguranca por Design

- Auto-extensao tem gate de aprovacao manual contra padroes de risco (exclusao de arquivos, execucao de comandos, eval/exec, registro do Windows, rede de baixo nivel, credenciais).
- `consultar_especialista` bloqueia uso de nuvem sem aprovacao explicita do usuario.
- `consultar_git` e somente-leitura por construcao, sem nenhum comando que altere o repositorio.
- `notificar_celular` usa um topico secreto unico gerado localmente, sem expor nenhuma credencial ou conta de terceiros.

Pendencias Conhecidas

- Concluir a vetorizacao BGE-M3 da tabela `base_conversas`
- Validar contagens `lyra_memory_v2` vs SurrealDB e comparar qualidade de busca antes de qualquer cutover de producao
- Reiniciar o `cerebro_maestro.py` para ativar o loop proativo