

LYRA — NÚCLEO DO PROJETO

> Consolidado em 22/06/2026. Atualizado em 02/07/2026.

1. Quem é o arquiteto

Antônio — estudante de ADS na UNIMAR (Marília-SP). Arquiteto único do projeto Lyra (IA pessoal local). Entendimento técnico sólido, prefere explicações diretas e sem enrolação. Treina bateria, frequenta academia.

— **Hardware:** Ryzen 7 3700X | RTX 2060 SUPER 8GB VRAM | 64GB RAM | 2.73TB HD

— **Email:** antonio.assuino.salomao@gmail.com

2. O que é a Lyra

IA pessoal local, identidade feminina, voz suave/técnica/clínica, não-servil. Não é um chatbot — é pensada como organismo cognitivo: hardware como corpo, modelos como córtex, SurrealDB+Qdrant como memória.

3. Ring 0 — Princípios Invioláveis

- **1.** Antônio é o Administrador Supremo. Protocolo de Sobrescrita anula qualquer raciocínio da máquina.
- **2.** core.py é somente leitura.
- **3.** 100% offline por padrão. Exceções conscientes aprovadas: cascata cloud (Groq→Gemini→Claude→local) desde 25/06/2026; TTS online; consultar_especialista(nivel="cloud") delega ao Claude Code sem aprovação por ação.
- **4.** Hardware-Bound Logic Gates — telemetria da placa-mãe/RTX/RAM como chave física.
- **5.** Toda auto-modificação de código requer aprovação explícita antes de produção.
- **6.** Ações de execução de alto risco exigem confirmação explícita no chat — Câmara de Eco Heurística (seção 4.4).

4. Arquitetura de Cognição e Memória

4.1 Camadas de memória

Camada	Tecnologia	Função
RAM (volátil)	Contexto LLM + cache quente	Working memory
Qdrant (vetores)	BAAI/bge-m3, 1024d (lyra_memory_v2), embed_service :8001	Memória semântica
SurrealDB (grafos)	Tabelas + relações ->	Memória episódica/temporal
Cold storage	Arquivos comprimidos em disco	Memória arquivada

Base atual: ~3.27M registros no SurrealDB. Funil de Eventos intercepta toda mensagem, grava timestamp, SurrealDB e Qdrant; últimas 10 msgs em RAM.

4.2 Shadow Thoughts — Ciclo de Sono

- ✓ **IMPLEMENTADO (01/07/2026)** — agendado automático a cada 3h no loop_proativo:
- **WAKE:** registra episódios novos (tag new_memory).
- **NREM:** dedup semântico (cosseno > 0.95) — marca duplicado=True, não apaga. 1ª execução: 28 duplicatas.
- **REM:** cria arestas 'conecta' cross-domain entre tópicos co-ocorrentes no SurrealDB.
- **DEEP SLEEP:** comprime eventos > 4 semanas em resumos semanais.
- **Endpoint:** POST /shadow_thoughts para disparo manual.

4.3 Memória em grafos nativos (SurrealDB)

- ✓ **IMPLEMENTADO.** _grafo_salvar_relacoes() cria, a cada evento, arestas evento→precedeu→evento (threading) e evento→sobre→topico:keyword (indexação). buscar_grafo_surreal() faz traversal e complementa o RAG. Exposto em GET /grafo.

4.4 Outros mecanismos cognitivos

- ✓ **Enxame de sub-agentes (lyra_agentes.py):** IMPLEMENTADO. Decompõe tarefa em N sub-tarefas paralelas via asyncio.Semaphore, consolida via LLM.
- ✓ **Enxame de especialistas (MoE roteado):** IMPLEMENTADO (02/07/2026). Lista declarativa ESPECIALISTAS roteia a cascata do /chat por categoria (codigo/geral).
- ✓ **Speculative Decoding:** IMPLEMENTADO (02/07/2026) — não acelera geração (inviável com APIs cloud); é sidecar de detecção de divergência semântica: draft qwen3:0.6b em paralelo, divergencia_draft = 1 - cosseno. Limiar 0.45, só loga, não bloqueia.
- ✓ **Câmara de Eco Heurística:** IMPLEMENTADO (02/07/2026) — v1 heurística por padrões (sem LLM). Bloqueia executar_comando/iniciar_processo_bg/escrever_arquivo/organizar_pasta de alto risco e exige confirmação explícita no turno seguinte.

4.5 Protocolo Darwin — Auto-evolução (Fase 5+)

Archive de versões, geração de variantes em sandbox RAM, rollback automático em regressão. ADAS (meta-agente): cria agentes para problemas recorrentes.

5. Interface / Front-end

- Sem janelas padrão do Windows — tudo flutua sobre o desktop via pywebview + Three.js.
- **Esfera de Partículas:** núcleo azul central com 3 camadas (60 brilhantes + 240 médias + 300 pequenas), fundo espacial com nebulosas, rotação suave, reage ao estado (idle/ouvindo/processando/falando).
 - **Painel Lateral:** conexões WS/Cérebro, estado, modelo, atividade (CPU/RAM/GPU/VRAM + sparkline), telemetria de tiers + sparkline histórico, serviços, botão de Grafo de Memória.
 - **Chat:** modal flutuante, export .md, limpeza de histórico, anexo de imagem/áudio, botão reler em voz alta por mensagem.
 - **Grafo de Memória 3D:** overlay fullscreen com 3d-force-graph v1.73.4 + Three.js r128. Lyra no centro fixada, tópicos na esfera Fibonacci, eventos como partículas. Busca de nós, detalhe ao clicar. Conectado ao SurrealDB via /grafo/completo.
 - ✗ **Axônios sinápticos:** chegou a ser implementado e testado, mas DESCARTADO (01/07/2026) por pedido do Antônio. Não reimplementar sem pedido novo.

6. Voz, Sentidos e Telemetria

- **Voz pipeline 1:** mic_engine.py — wake word 'lyra' → Silero VAD → faster-whisper 'small' → /chat. TTS PAUSADO por decisão do usuário.
- **Voz pipeline 2 (Voice Live):** botão dedicado, Gemini Live API (gemini-2.5-flash-native-audio-latest), WEBSOCKET /ws/voice, bidirecional em tempo real.
- **Visão Semântica:** explicar_tela() via Gemini Vision (primário) + llava-phi3 (fallback). analisar_imagem() para imagens em disco.
- **Emotion Engine:** planejado — análise paralinguística, 40+ estados via pitch/tempo/tremor.
- **Wi-Fi Sensing:** planejado — CSI via ESP32 como sonar passivo (802.11bf).

7. Stack Técnico Atual (canônico — 02/07/2026)

CAMADA	TECNOLOGIA
Interface	Three.js + pywebview (TS/JS)
WebSocket hub	ws://127.0.0.1:8765 (lyra_app.py)
Backend/API	FastAPI :8000 (cerebro_maestro.py) — expõe MCP em /mcp
LLM Engine	Ollama + cascata cloud Groq→Gemini→Claude→local
LLM Principal	Groq gpt-oss-120b / Gemini 3.5-flash / Claude Sonnet / qwen3:8b (fallback)
Embedding	BAAI/bge-m3 (1024d) via embed_service :8001 — migração CONCLUÍDA
Reranker	bge-reranker-v2-m3 (cross-encoder) via embed_service :8001 /rerank
BM25 esperso	bm25s — bm25s_index/ + bm25s_meta.pkl. /buscar ~382ms
Vector DB	Qdrant standalone :6333 (v1.17.1 FIXADO — não atualizar)
Graph+Doc DB	SurrealDB 3.0.5 (:8090, NS 'lyra_core', DB 'Db_CORTEX')
TTS	PAUSADO por decisão do usuário
STT	faster-whisper 'small' (CPU int8)
Visão	Gemini Vision (primário) + llava-phi3 (fallback)
Agente ReAct	lyra_agent.py — loop ReAct + POST /agente
Enxame	lyra_agentes.py — asyncio.Semaphore, fan-out/fan-in
Shadow Thoughts	lyra_shadow_thoughts.py — NREM/REM/DEEP, cron ~3h
Segurança	lyra_seguranca.py — sandboxing + Câmara de Eco Heurística
Integrações	lyra_telegram.py, lyra_browser.py, lyra_google_workspace.py

8. Roadmap por Fases

- ✓ **[Fase 0-1]** Ingestão de datasets, vetorização Qdrant, Modelfile, commands.py, audio_manager.py, mic_engine.py, webcam.py, frontend pywebview, Funil de Memória
- ✓ **[Fase 2]** lyra_tools.py (acesso total ao PC), auto-extensão
- ✓ **[Fase 2]** Cascata de modelos cloud (Groq→Gemini→Claude→local)
- ✓ **[Fase 2]** Hybrid RAG (BM25 bm25s + BGE-M3 dense + RRF + bge-reranker-v2-m3)
- ✓ **[Fase 2]** Enxame de sub-agentes paralelos (lyra_agentes.py)
- ✓ **[Fase 2]** Grafo de Memória 3D (3d-force-graph + Three.js)
- ✓ **[Fase 2]** lyra_agent.py (loop ReAct + self-test) + integrado ao backend POST /agente
- ✓ **[Fase 2]** Geração de imagens (gerar_imagem() via Pollinations.ai)
- ✓ **[Fase 2]** Voz Live bidirecional (Gemini Live, /ws/voice)
- ✓ **[Fase 3]** Shadow Thoughts (NREM/REM/DEEP) — agendado 3h
- ✓ **[Fase 3]** 5 Inovações Cognitivas: Goal Drift, Freshness Tags, Session Replay, Cognitive Load, Response Provenance
- ✓ **[Fase 3]** Telemetria histórica (sparkline de cascata, /stats/historico)
- ✓ **[Fase 3]** Reconciliação SurrealDB↔Qdrant (reconciliar_episodios.py)
- ✓ **[Fase 3]** Refactor cascata — executar_chat_com_tools() compartilhado
- ✓ **[Fase 3]** Speculative Decoding (sidecar de detecção de alucinação)

- ✓ **[Fase 3]** Enxame de especialistas (MoE roteado)
- ✓ **[Fase 3]** Câmara de Eco Heurística (bloqueio de ações de risco)
- **[Fase 4]** Emotion Engine (voz paralinguística, 40+ estados)
- **[Fase 4]** Wi-Fi Sensing via ESP32 (802.11bf CSI)
- **[Fase 5]** Protocolo Darwin (auto-reescrita supervisionada, ADAS)
- ◇ **[Fase 6]** BCI OpenBCI ESP-EEG, Protocolo Narciso (digital twin)

9. Visão de Longo Prazo

- Sistema de Arquivos Líquido — hard links que 'brotam' conforme contexto.
- Total Recall — OCR contínuo de tela indexado.
- Telepatia de Clipboard — intercepta Ctrl+C, age antes do Ctrl+V.
- DNA de Projeto — versionamento semântico que guarda a intenção, não só o diff.
- OPSEC avançado — esteganografia de núcleo, sandbox hipertempo em RAM, honeypot USB, CRYSTALS-Kyber.
- Soberania acadêmica — mentor UML/Java, resumidor automático de PDFs de aula.
- Sensor Fusion — unifica Wi-Fi CSI + microfone + teclado + câmera num modelo de estado global.
- Ghost OS Level 2 — isolamento via namespace/eBPF.

"Não é uma IA. É uma extensão do sistema nervoso."

LYRA — REFERÊNCIA TÉCNICA

> Consolidado em 25/06/2026. Atualizado em 02/07/2026.

1. Padrões Técnicos Confirmados (não quebrar)

- ✓ Embedding padrão: BAAI/bge-m3 (1024 dims) — migração CONCLUÍDA (26/06/2026). Coleção lyra_memory_v2, ~3.09M vetores, 100% GPU.
- embed_service.py (:8001) serve BGE-M3 + reranker bge-reranker-v2-m3 como microserviço HTTP.
- cerebro_maestro.py NÃO carrega sentence_transformers direto.
- ✗ NUNCA usar ENCODE_BATCH acima de 32 nem MAX_SEQ_LEN > 512 — estoura VRAM.
- ✗ CRÍTICO — usar 127.0.0.1, NUNCA localhost, em chamadas internas. localhost ~2050ms vs 127.0.0.1 ~5-20ms no Windows (resolver tenta IPv6 primeiro).
- UUID determinístico (uuid5) para IDs do Qdrant — hash() colidia e não era idempotente.
- Paginação por cursor no SurrealDB (WHERE id > \$cursor), nunca LIMIT/START com 1M+ registros.
- ✗ CRÍTICO — import pyarrow ANTES de torch (Windows). Ordem trocada gera access violation 0xc0000005 sem traceback.
- ✗ NUNCA atualizar binário do Qdrant sem backup completo de qdrant_data/ — v1.17.1→v1.18.2 já descartou ~666k vetores. Fixado em v1.17.1.
- ✓ venv_embed (5GB) APOSENTADO (30/06/2026) — Python principal atualizado pra torch 2.6+cu124, embed_service roda nele direto.
- ✗ Decay Ebbinghaus — REMOVIDO (01/07/2026). Score = relevancia*0.94 + freshness_factor*0.06 (Knowledge Freshness Tags, seletivo por categoria).
- sys.stdout.reconfigure(encoding='utf-8', errors='replace') obrigatório em todo script com output redirecionado.
- SurrealDB porta 8090, DB 'Db_CORTEX' (case-sensitive). Headers HTTP surreal-ns/surreal-db (não NS/DB).

2. Bugs e Melhorias

Resolvidos recentemente (01-02/07/2026)

- ✓ Refactor cascata — executar_chat_com_tools() compartilhado elimina 3 cópias do loop de tool-calling. _MAX_ITERACOES_TOOLS=25.
- ✓ Reconciliação SurrealDB↔Qdrant — 15 episódios órfãos de 26/06 recuperados por reconciliar_episodios.py.
- ✓ 5 Inovações Cognitivas: Goal Drift Detector, Knowledge Freshness Tags, Session Replay, Cognitive Load Throttling, Response Provenance.
- ✓ MoE roteado (ESPECIALISTAS) — lista declarativa formaliza o roteamento código/geral da cascata do /chat.
- ✓ Speculative Decoding — sidecar de detecção de divergência semântica (qwen3:0.6b draft em paralelo).
- ✓ Câmara de Eco Heurística — bloqueio de ações de risco (deleção/formatação/shutdown/etc) com confirmação explícita no turno seguinte.
- ✓ navegar_web (browser-use) corrigido de ponta a ponta — Chromium instalado, API nova do browser-use (ChatGoogle), modelo Gemini com quota real.
- ✓ Auditoria geral de bugs (02/07/2026): encoding corrompido em executar_comando/abrir_app (PowerShell OEM vs UTF-8), keyring apagando chaves não-conhecidas do .env, race condition em /chat misturando respostas entre requisições concorrentes, modelo Gemini inexistente em analisar_clipboard_com_ia, falha silenciosa do Gemini Vision em explicar_tela.
- ✓ Bug de regressão: Groq rejeitava mensagens com campos extras (fontes_rag/divergencia_draft) — sanitização de mensagens antes de enviar à API.

Pendentes / Melhorias futuras

- [MÉDIA] Migrar frontend Three.js para WebGPURenderer (r171+).
- [BAIXA] Separar validação do RAG por categoria (episodio vs conhecimento_geral) no validador_cortical.py.
- [BAIXA] Avaliar estado input-required do A2A para sub-agentes que precisam perguntar ao Antônio.
- Tarefas manuais pendentes (ver instrucoes.md): Telegram bot, Google OAuth, Screenpipe, atualizar SurrealDB via winget, registrar MCP em ~/.claude/settings.json.
- Validar Voz Live ponta a ponta com microfone físico real.
- Confirmar visualmente sparkline histórico #t-hist-spark no painel lateral.

3. Referência da API HTTP (cerebro_maestro.py :8000)

28 endpoints. Endpoints principais cobertos por test_smoke.py (17 checagens). Atualizado 02/07/2026.

Método	Rota	Descrição
GET	/	Ping — {servico, ativo, versao}
GET	/dashboard	Dashboard HTML standalone
GET	/status	Estado (cerebro_ativo, qdrant, embedder, tts_mudo, carga_cognitiva)
GET	/health	Latência real Qdrant/SurrealDB/Ollama + VRAM + contagem
GET	/metrics	CPU/RAM (psutil) + GPU/VRAM% (nvidia-smi, cache 4s)
GET	/stats	Telemetria cascata: usos/falhas/latência/% por andar
GET	/stats/historico	Snapshots históricos de cascata (telemetria_historico.jsonl)
POST	/chat	Chat principal SSE streaming. Body: {texto, modelo}
GET	/buscar	Busca híbrida BM25+BGE-M3+RRF+freshness+reranker
GET	/grafo	Traversal de grafo SurrealDB por keywords
GET	/grafo/completo	Grafo completo para o visualizador 3D
GET	/memoria/categorias	Composição da base por categoria (Qdrant)
GET	/historico	Histórico em memória (inclui fontes_rag/divergencia_draft)
DELETE	/historico	Limpa histórico em memória (não afeta SurrealDB/Qdrant)
GET	/resumo_sessao	Briefing + histórico (preview)
GET	/exportar	Exporta sessão como markdown
POST	/tts/mudo	Liga/desliga voz global. Body: {mudo: bool}
POST	/tts/falar	Dispara TTS para texto arbitrário. Body: {texto}
POST	/upload	Upload de imagem/áudio do chat
POST	/enxame	Cria enxame de sub-agentes
GET	/enxames	Lista enxames recentes
GET	/enxame/{id}	Status do enxame + subtarefas
POST	/enxame/{id}/consolidar	Consolida resultados via LLM
POST	/agente	Loop ReAct autônomo. Body: {objetivo, max_iteracoes}
GET	/agente/runs	Lista execuções recentes de agente_run
POST	/shadow_thoughts	Dispara ciclo Shadow Thoughts em background
WS	/ws/voice	Voice Live bidirecional (Gemini Live API)
GET/POST	/mcp	Todos os endpoints acima como ferramentas MCP

4. Hybrid RAG — Arquitetura

Query → [BM25 esparso (bm25s)] + [Dense vetorial (BGE-M3)] → merge (RRF) → bge-reranker-v2-m3 → freshness → top-K → LLM

- **BM25 (bm25s)**: ~382ms sobre 3.08M docs (era 2.1s com rank_bm25). Acerta nomes próprios/siglas/código exato.
- **Dense (BGE-M3)**: 1024 dims, normalizado, GPU via embed_service :8001. Acerta semântica/sinonímia.
- **RRF**: Reciprocal Rank Fusion — combina listas sem ajuste de escala.
- **Reranker (bge-reranker-v2-m3)**: cross-encoder 3º estágio.
- **Score final**: relevancia*0.94 + freshness_factor*0.06. Ebbinghaus decay REMOVIDO (01/07/2026); freshness é seletivo por categoria (código 180d, wiki 3650d, matemática/episódio sem penalidade).

5. Módulo de Expansão & Modo Construção

Validador Cortical de RAG (validador_cortical.py)

Gera perguntas sintéticas a partir de registros aleatórios do Db_CORTEX e mede Hit Rate (top-K) e MRR. Política de rollback: HR_Min 85% | MRR_Min 0.68.

Task-Aware Budgeting

Detecta transição de domínio (chat casual → debug técnico) e resume (não descarta) mensagens de baixa densidade técnica.

Modo Construção — chaveamento de modelos

	Modo Chat	Modo Construção
Modelo	Cascata cloud ou qwen3:8b	Qwen3.6 27B / DeepSeek-R1 32B distilled
Hardware	8GB VRAM	64GB RAM (GPU offload via LM Studio)
Vazão	>40 tok/s	5-10 tok/s

6. Datasets Ingeridos

Schema: { titulo, texto (max 3000), fonte, categoria }. Script: Scripts_Ingestao/pipeline_noturno.sh

Tabela	Dataset	Conteúdo
wiki_conhecimento	wikimedia/wikipedia 20231101.pt	1.112.246 artigos PT-BR
base_codigo	nickrosh/Evol-Instruct-Code-80k-v1	80k pares instrução/código
base_codigo	iamtarun/code_instructions_120k_alpaca	120k instruções Python
base_codigo	sahil2801/CodeAlpaca-20k	20k instruções código geral
base_codigo	iamtarun/python_code_instructions_18k_alpaca	18k Python específico
base_instrucoes_ptbr	dominguesm/Canarim-Instruct-PTBR-Dataset	316k instruções PT-BR nativo
base_instrucoes_ptbr	CohereLabs/aya_dataset (por=por)	Instruções PT-BR curadas
base_raciocinio	openai/gsm8k	8.5k problemas matemáticos CoT
base_raciocinio	meta-math/MetaMathQA	395k QA matemático passo a passo
base_conversas	teknium/OpenHermes-2.5	~1M conversas alta qualidade (GPT-4)
base_conhecimento_qa	piEsposito/br-quad-2.0	SQuAD 2.0 traduzido PT-BR
base_conhecimento_qa	eraldoluis/faqquad	QA nativo PT-BR (ensino superior)
base_medicina_ptbr	AKCIT/MedPT	384.095 pares Q&A médicas PT-BR

7. Melhores LLMs Locais (referência 2026)

Modelo	Uso	Notas
qwen3:8b	Fallback local atual da Lyra	Cascata cloud vai na frente
qwen3:0.6b	Draft sidecar (spec decoding)	Detecção de divergência semântica
Groq gpt-oss-120b	1º andar cascata cloud	Free tier
Gemini 3.5-flash	2º andar cascata cloud	Free tier
Claude Sonnet (via Claude Code)	3º andar — delegação completa	Full agent, ferramentas nativas
Qwen3.6 27B	Candidato Modo Construção	Via RAM offload (64GB)
DeepSeek-R1 distilado 7B	Raciocínio chain-of-thought local	~5-10 tok/s

8. Modelos de Embedding

Modelo	Dims	Status
BAAL/bge-m3	1024	EM USO — lyra_memory_v2, GPU via embed_service :8001
bge-reranker-v2-m3	—	EM USO — cross-encoder reranker, 3º estágio do RAG
paraphrase-multilingual-MiniLM-L12-v2	384	APOSENTADO — lyra_memory v1 apagada
jina-embeddings-v3	1024	Referência — melhor qualidade multilingual
nomic-embed-text-v1.5	768	Referência — excelente PT-BR local

9. VLMs em 8GB

Modelo	VRAM	Status
Gemini Vision (gemini-2.5-flash)	Cloud	Primário — explicar_tela() e analisar_imagem()
llava-phi3	~2.9GB	Fallback local via Ollama
SmoIVLM 2B	~1.5GB	Alternativa local rápida
MiniCPM-V 2.6	~5.5GB	Melhor qualidade, concorre com LLM principal

10. Geração de Imagem/Vídeo/Áudio

— **Imagem:** Pollinations.ai (gratuito, sem key, Flux) — em uso via gerar_imagem(). ComfyUI + SD 1.5 (~2GB VRAM) como alternativa local.

— **Vídeo:** LTX-2 OPTIMIZED (único viável em 8GB, FP8, 2-5s de vídeo em 60-90s). NÃO roda simultâneo com o LLM.

— **Áudio/Música:** MusicGen Small (~1GB VRAM), AudioLDM2 (~2GB).

11. Sessão 02/07/2026 — Itens Implementados

Câmara de Eco Heurística — bloqueio de ações de risco

lyra_seguranca.avaliar_risco_acao() avalia executar_comando/iniciar_processo_bg/escrever_arquivo/organizar_pasta. Hash SHA256 determinístico liga uma confirmação à ação exata; só aceita no turno IMEDIATAMENTE seguinte ao bloqueio (contador monotônico, imune a truncamento de histórico). Validado ao vivo: Stop-Process bloqueado, 'sim, executa mesmo assim' libera, erro benigno reportado corretamente.

Speculative Decoding — sidecar de detecção de divergência

Draft qwen3:0.6b roda em paralelo à cascata principal (só quando não precisa tools). divergencia_draft = 1 - cosseno(vetor_final, vetor_draft) via BGE-M3. Limiar 0.45 só loga, não bloqueia. Limitação conhecida: mede similaridade de tópico/estrutura, não correção factual (teste manual com resposta errada mas mesma estrutura deu divergência baixa).

MoE roteado — ESPECIALISTAS

Lista declarativa formaliza o roteamento condicional que já existia (código→Claude primeiro, geral→Groq primeiro). Ganho estrutural: adicionar especialista novo é uma entrada na lista, não editar if/else espalhado.

navegar_web (browser-use) corrigido de ponta a ponta

3 problemas em cadeia: Chromium nunca instalado; API do browser-use migrou pra abstração própria (ChatGoogle em vez de langchain ChatGoogleGenerativeAI); modelo gemini-2.0-flash com quota zero, trocado por gemini-2.5-flash. Validado ao vivo — ciclo completo funcional.

Auditoria geral de bugs — 3 sub-agentes em paralelo

6 bugs reais corrigidos: modelo Gemini inexistente em analisar_clipboard_com_ia; falha silenciosa do Gemini Vision em explicar_tela; encoding corrompido em executar_comando/abrir_app (PowerShell OEM vs UTF-8); migrar_chaves_para_keyring apagava chaves não-conhecidas do .env (risco: TELEGRAM_ALLOWED_USERS sumindo abre o bot pra qualquer usuário); race condition em /chat podia misturar respostas entre requisições concorrentes. test_smoke.py 17/17 após todas as correções.

LYRA — AGENTES PARALELOS E PLANOS

> Consolidado em 25/06/2026. Atualizado em 02/07/2026.

1. Enxame de Sub-Agentes (lyra_agentes.py) — IMPLEMENTADO

Implementado em 26/06/2026. Status: produção.

- Dispara N sub-tarefas em paralelo via asyncio.Semaphore(max_paralelo=2).
- Cada sub-tarefa usa cascata Groq→Gemini isolada com tool-calling real.
- Persistência em SurrealDB (tabelas enxame + subtarefa).
- Toolset: denylist (não allowlist) — bloqueia só destrutivo/recursivo/auto-modificante.
- Endpoints: POST /enxame, GET /enxame/{id}, POST /enxame/{id}/consolidar, GET /enxames.
- Ferramentas em lyra_tools: criar_enxame, status_enxame, consolidar_enxame.
- loop_proativo detecta enxames concluídos e notifica automaticamente.

2. lyra_agent.py (loop ReAct) — IMPLEMENTADO

Implementado em 30/06/2026. Integrado ao backend em 01/07/2026. _rodar_local validado ao vivo em 02/07/2026.

- Loop ReAct standalone autônomo — separado do chat.
- executar_agente_async(objetivo, max_iteracoes) — API pública assíncrona.
- Cascata Groq→Gemini→local (mesmo padrão do cerebro_maestro, sem streaming).
- Persiste em SurrealDB tabela agente_run: objetivo, iteracoes, passos, resposta_final, sucesso.
- TOOLS_BLOQUEADAS_PADRAO: bloqueia destrutivo/recursivo/auto-modificante.
- ✓ self_test() valida 3 casos: aritmética sem tool, busca com tool, tool inexistente. 3/3.
- ✓ _rodar_local validado ao vivo: 3/3 casos passaram via Ollama local direto, confirma loop ReAct igual nos 3 andares.
- Endpoint POST /agente + GET /agente/runs no cerebro_maestro.py.

3. Shadow Thoughts (lyra_shadow_thoughts.py) — IMPLEMENTADO

Fase	O que faz	Quando roda
NREM	Dedup semântico (cosseno > 0.95), marca duplicado=True	A cada ciclo (~3h)
REM	Arestas 'conecta' cross-domain entre tópicos co-ocorrentes	A cada ciclo (~3h)
DEEP	Comprime eventos >4 semanas em resumos semanais	A cada ciclo (~3h)

- Disparado automaticamente a cada 180 iterações do loop_proativo (~3h).
- Endpoint POST /shadow_thoughts para disparo manual (fases=nrem,rem,deep).
- Segurança: NREM não deleta — só marca. REM usa RELATE upsert. DEEP cria resumo e marca comprimido=True.

4. Backlog Pendente

Prioridade	Item	Notas
ALTA	Telegram bot (@BotFather + .env TELEGRAM_BOT_TOKEN)	instrucoes.md item pendente
ALTA	Google OAuth (Gmail + Calendar)	lyra_google_workspace.py
ALTA	Registrar MCP: ~/.claude/settings.json → url http://127.0.0.1:8000/mcp	Conecta Claude Code à Lyra
MÉDIA	npm install -g @screenpipe/cli	Total Recall — OCR contínuo
MÉDIA	SurrealDB update via winget	Versão mais recente
MÉDIA	Migrar frontend Three.js → WebGPURenderer (r171+)	Performance gráfica
BAIXA	Validar Voice Live com microfone físico real	End-to-end áudio
BAIXA	Confirmar sparkline #t-hist-spark no painel lateral	Visual
BAIXA	Estado input-required para sub-agentes (ideia do A2A)	v2 do enxame
FUTURA	Emotion Engine (paralingüística)	Fase 4
FUTURA	Wi-Fi Sensing via ESP32 (802.11bf)	Fase 4

5. Pesquisas Técnicas Realizadas

- SurrealDB 3.0 vs Qdrant para vector search: NÃO migrar agora — ~15-20GB RAM, esforço alto, Qdrant já estável (~382ms). Revisar quando Qdrant mostrar dor real.
- Mem0 / Kore para decay de memória: Kore confirma abordagem atual (Freshness Tags seletivo). Mem0 foca resolução de conflitos, não decay. Manter implementação atual.
- Protocolo A2A (Agent-to-Agent): NÃO adotar — resolve interop entre fornecedores diferentes, problema que a Lyra não tem. Ideias aproveitadas: ciclo de vida rico + Agent Cards, base pra lista ESPECIALISTAS.
- Baseline RAG (calibrar_pesos_rag.py): diferença entre pesos não significativa (n=40). Decay removido — score = relevância pura + freshness seletivo.

Gerado em 02/07/2026 a partir de LYRA_NUCLEO.md + LYRA_TECNICO.md + LYRA_AGENTES_E_PLANOS.md.